PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Documentação da entrega

Projeto Perfil das faixas populares nos charts da Deezer por gênero

Curso e turma Bacharelado em Sistemas de Informação • 2º semestre de 2026

Professor ou professora Marina de Lara

Equipe Eduardo Fabri • João Correa • Rodrigo Alves • João Pedro Cardoso

Repositório https://github.com/Jcliz/data-analytics

Entrega Curitiba • 21/10/2026

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

Os charts da Deezer mostram as faixas mais ouvidas no geral e em cada gênero. Artistas, gravadoras e curadores de playlists os usam para decidir o que lançar e promover, mas o chart traz só a ordem das faixas, não o que elas têm em comum. Este projeto descreve o perfil das faixas do topo de cada gênero: duração, idade do lançamento, popularidade do artista e concentração de poucos artistas no ranking. Saber se esse perfil muda entre gêneros ajuda quem produz e divulga música a comparar a própria faixa com o que se ouve no gênero dela.

Objetivo e recorte

Objetivo: montar um conjunto de dados confiável com as faixas dos charts da Deezer e os atributos da faixa, do álbum e do artista, para comparar o perfil das faixas populares entre gêneros nas etapas seguintes.

Período: um único retrato dos charts, na data da coleta registrada na seção 02 (ficha da fonte). O chart é ao vivo; o projeto não acompanha sua evolução.

Unidade de observação: a faixa (objeto `track` da API). Uma faixa pode estar em mais de um chart; o gênero de comparação é o do chart em que ela aparece.

População coberta: as primeiras posições do chart geral e dos charts de cada gênero listado pela API (`/genre` e `/chart/{id_genero}/tracks`), com o detalhe de cada faixa, álbum e artista.

Limites: só faixas dos charts, não o catálogo inteiro; charts vistos a partir do país da coleta, registrado na seção 02; sem número de reproduções, só o `rank`, índice de popularidade calculado pela Deezer; atributos de áudio como `bpm` ficam fora das perguntas, porque a API costuma devolvê-los zerados quando não os calculou.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como a duração das faixas varia entre os gêneros dos charts da Deezer na data da coleta?	duration (segundos) da faixa; gênero do chart de origem (/genre, /chart/{id_genero}/tracks)
P2	Que parte das faixas de cada chart de gênero foi lançada nos 12 meses anteriores à coleta?	release_date de /track/{id}; gênero do chart de origem; data da coleta
P3	Faixas de artistas com mais fãs têm rank mais alto, no chart geral e dentro de cada gênero, na data da coleta?	rank da faixa; nb_fan de /artist/{id}; gênero do chart de origem
P4	Quantos artistas distintos ocupam as posições de cada chart de gênero e que fatia dessas posições fica com os 5 artistas com mais faixas?	artist.id do item do chart; position; gênero do chart de origem

Viabilidade inicial

Todos os campos das perguntas existem na API pública da Deezer, sem autenticação: duration, rank, position e artist.id em /chart/{id_genero}/tracks, release_date em /track/{id}, nb_fan em /artist/{id} e os gêneros em /genre (fontes 1 e 2; base/api-deezer.md, seções 2 e 3). Coletar cada chart de gênero registra o gênero de origem em cada item, sem depender do gênero do álbum.

Lacunas a confirmar na seção 03: a faixa pode estar no chart geral e no do seu gênero, e a deduplicação precisa preservar o gênero de origem; release_date e nb_fan podem vir ausentes ou zerados, reduzindo a base de P2 e P3; o gênero do chart, da Deezer, pode diferir do gênero do álbum; e um único retrato não mostra tendência.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação F1 • Charts de faixas da Deezer (geral e um por gênero), com os detalhes de cada faixa, álbum e artista.

Origem e acesso Deezer • API pública https://api.deezer.com, sem autenticação nem chave (documentação: https://developers.deezer.com/api) • data de acesso: 16/10/2026.

Formato e volume JSON via API REST, gravado como recebido (57,7 MB no retrato de 16/10/2026) • 2.800 itens em 28 charts, com 2.581 faixas, 2.292 álbuns e 1.688 artistas únicos • atributos da faixa (id, title, duration, rank, explicit_lyrics, preview, position, bpm, isrc, release_date), do álbum (genre_id, genres, label, release_date, record_type, nb_tracks) e do artista (name, nb_fan, nb_album); o df_bruto tem 102 colunas.

Cobertura charts do dia da coleta, sem histórico; cada um traz as 100 faixas mais populares no momento da requisição (total = 100 em todos) • país aparente: US (Estados Unidos) • charts: o geral (gênero 0) e os gêneros de /genre.

Condições de uso API pública; os dados pertencem à Deezer e aos detentores de direitos e são usados só para fins acadêmicos, sem redistribuir as prévias de áudio. A coleta respeita o limite de chamadas com pausa entre requisições.

Relação com o problema

Todos os campos das quatro perguntas (seção 01) vieram no retrato de 16/10/2026 e estão no df_bruto, e cada item guarda o chart de gênero de origem:

- **P1** (duração por gênero): duration e o gênero do chart (chart_id_genero, chart_nome_genero).
- **P2** (lançamentos dos 12 meses anteriores à coleta, por gênero): detalhe_faixa_release_date, o gênero do chart e a data da coleta, no metadados.json.
- **P3** (fãs do artista e rank): rank, detalhe_artista_nb_fan e o gênero do chart.
- **P4** (concentração de artistas por chart): artist_id, position e o gênero do chart.

Por ser de um único dia e país aparente (US), a fonte não apoia perguntas sobre evolução no tempo nem comparações entre países.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Acesso: GET em https://api.deezer.com, pausa de 0,15 s, até 4 tentativas com espera crescente; o objeto error devolvido com HTTP 200 é tratado (código 4, limite de chamadas, ganha nova tentativa; os demais são registrados)	notebook §2, célula "Parâmetros da coleta e acesso à API"

Etapa	Procedimento ou parâmetro	Evidência no repositório
2	Charts: /genre lista os gêneros e /chart/{id}/tracks traz o geral e cada gênero, paginado por index e limit=100, até o fim ou 300 itens; /infos registra o país aparente	notebook §2, célula "Coleta dos charts por gênero"
3	Detalhes: /track/{id}, /album/{id} e /artist/{id} para cada faixa, álbum e artista únicos	notebook §2, célula "Coleta dos detalhes de faixas, álbuns e artistas"
4	Retrato bruto: respostas cruas em dados/brutos/AAAA-MM-DD/ (infos.json, generos.json, charts.json, faixas.json, albuns.json, artistas.json) e metadados.json (início e fim, país, parâmetros, chamadas por endpoint, novas tentativas e erros). As etapas 2 a 4 só rodam com BAIXAR_DA_API = True	notebook §2, célula "Gravação do retrato bruto"; dados/brutos/2026-10-16/
5	Leitura: com BAIXAR_DA_API = False (padrão), lê o retrato mais recente de dados/brutos/ e mostra o metadados.json	notebook §2, células "Leitura do retrato bruto mais recente" e "Metadados do retrato lido"
6	df_bruto: uma linha por item de chart, com a origem (chart_id_genero, chart_nome_genero, chart_ordem) e os campos de faixa, álbum e artista juntados pelo id (prefixos detalhe_faixa_, detalhe_album_, detalhe_artista_), sem limpeza e com as repetições entre charts	notebook §2, célula "Montagem do df_bruto"
7	Verificação: linhas contra os metadados, faixas, álbuns e artistas únicos, itens sem detalhe, colunas por origem e itens por chart	notebook §2, célula "Verificação do carregamento"

Resultado da ingestão

A coleta de 16/10/2026 (21h03 a 21h41 UTC) fez 6.591 chamadas, sem novas tentativas nem erros (dados/brutos/2026-10-16/metadados.json). Os 28 charts (o geral e 27 gêneros) vieram com 100 itens cada, numa página: é o que a API oferece (total = 100), abaixo do teto de 300. O df_bruto tem 2.800 linhas e 102 colunas, com 2.581 faixas, 2.292 álbuns e 1.688 artistas únicos, e nenhum item sem detalhe (notebook §2, célula "Verificação do carregamento"). O retrato fica versionado em dados/brutos/AAAA-MM-DD/ e toda execução lê o mesmo. A única etapa manual é a coleta, feita uma vez no Google Colab ou na máquina de um integrante (a API exige acesso direto à internet), com o retrato enviado ao repositório.

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação ocorrência de faixa num chart de origem, no retrato de 16/10/2026: 2.800 ocorrências, 102 atributos, 2.581 faixas, 28 charts (geral e 27 gêneros). Evidência: notebook §3, célula “Visão geral e tipos observados”, sobre dados/brutos/2026-10-16/.

Identificação dos registros id identifica a faixa e se repete entre charts; a chave é o par chart_id_genero e id, com zero excedentes em 2.800 (retratos futuros exigirão a data na chave). A posição pertence ao chart, não à faixa. Evidência: notebook §3, célula “Duplicidade e limite da chave”.

Dicionário inicial dos dados

Atributos usados pelas P1–P4, pelo RA2 e por este diagnóstico; os demais (URLs, capas, países, colaboradores) ficam no bruto. Os 102 atributos e suas ausências estão nas células “Visão geral e tipos observados” e “Ausências nulas e textos vazios”. Tipos do pandas 2.3.3; textos são object, sem conversão de data.

Atributo	Significado	Tipo e formato	Unidade ou domínio
chart_id_genero	Id do chart de origem; grupo das P1–P4	int64	Inteiro ≥ 0; 0 = geral
chart_nome_genero	Nome do chart; grupo das P1–P4 e gênero do evento RA2	object	Texto; All = geral
chart_ordem	Ordem da ingestão; verifica a posição (P4)	int64	Inteiro positivo, por chart
id	Id da faixa nas P1–P4; origem de id_faixa no RA2	int64	Inteiro positivo; repete entre charts
title	Título; identificação nas P1–P4	object	Texto
title_version	Versão; ausência informativa	object	Texto ou nulo; vazio permitido
duration	Duração (P1); limite da duração ouvida no RA2	int64	Segundos, inteiro positivo
rank	Popularidade (P3); peso do sorteio no RA2	int64	Inteiro ≥ 0; não é a posição
position	Posição no chart (P4)	int64	Inteiro positivo
explicit_lyrics	Conteúdo explícito; verificação de tipo	bool	Booleano

Atributo	Significado	Tipo e formato	Unidade ou domínio
preview	URL da prévia; ausência, sem uso nas P1–P4	object	Texto, pode ser vazio
artist_id	Id do artista (P3 e contagem da P4)	int64	Inteiro positivo
artist_name	Nome do artista (P3–P4, evento RA2)	object	Texto; agrupar pelo id
album_id	Id do álbum; chave do enriquecimento	int64	Inteiro positivo
detalhe_faixa_id	Id de /track; integridade da junção	int64	Domínio de id
detalhe_faixa_duration	Duração em /track; consistência com duration	int64	Segundos, inteiro positivo
detalhe_faixa_rank	Rank em /track; consistência com rank	int64	Inteiro ≥ 0
detalhe_faixa_release_date	Lançamento da faixa (P2), não do álbum	object	AAAA-MM-DD; até a coleta
detalhe_faixa_bpm	Andamento; diagnóstico, sem uso nas P1–P4	float64	BPM, real; zero a avaliar
detalhe_faixa_gain	Ganho; diagnóstico, sem uso nas P1–P4	float64	dB, real; negativo válido, zero a avaliar
detalhe_album_id	Id de /album; integridade da junção	int64	Domínio de album_id
detalhe_album_genre_id	Gênero do álbum; não é o grupo das P1–P4	int64	Inteiro; ≤ 0 é genérico
detalhe_album_release_date	Lançamento do álbum; formato, não substitui a data da P2	object	AAAA-MM-DD; até a coleta
detalhe_artista_id	Id de /artist; integridade da junção	int64	Domínio de artist_id
detalhe_artista_nb_fan	Fãs do artista (P3)	int64	Inteiro ≥ 0

Diagnóstico de qualidade

Denominador: **2.800 ocorrências**; as verificações não se somam e repetições contam só os excedentes.

Q1 cobre id, chart_id_genero, chart_nome_genero, title, duration, rank, position, artist_id, artist_name, album_id, detalhe_faixa_release_date e detalhe_artista_nb_fan. Q7 espera inteiros nas chaves e contagens, reais em BPM e gain e booleano em explicit_lyrics. Q8 sinaliza

não finitos, valores não positivos em duração, posição e ids, e negativos em rank, fãs ou BPM; não há teto de rank, e gain negativo é válido.

Em Q11, a faixa 4346251442, “Dirty Bird”, tem data 2026-10-28 (faixa e álbum), posterior à coleta de 16/10; talvez lançamento anunciado, causa não confirmada. Em Q17, os limites são 66,5 a 366,5 s, e as durações vão de 41 a 2.120 s. Em Q18, os limites de rank são −445.721,75 a 1.316.536,25. Evidências: células “Datas, formatos e categorias” e “Possíveis outliers e integridade do enriquecimento”.

Uma ocorrência não tem capa nem lista de faixas do álbum (1/2.800; 0,04%), metadados fora das P1–P4 e do RA2. Em title_version, há 57 nulos e 2.476 vazios: versão não informada, sem motivo para excluir faixa. Evidência: célula “Ausências nulas e textos vazios”.

ID	Verificação e regra	Resultado observado	Evidência
Q1	Ausência em campo essencial às P1–P4 ou RA2	0/2.800 (0,00%)	“Ausências nulas e textos vazios”
Q2	Ausência de preview (nulo ou vazio)	1/2.800 (0,04%)	“Ausências nulas e textos vazios”
Q3	Ausência de title_version (nulo ou vazio)	2.533/2.800 (90,46%)	“Ausências nulas e textos vazios”
Q4	Excedentes por id	219/2.800 (7,82%)	“Duplicidade e limite da chave”
Q5	Excedentes pelo par chart_id_genero e id	0/2.800 (0,00%)	“Duplicidade e limite da chave”
Q6	Linhas inteiras repetidas	0/2.800 (0,00%)	“Duplicidade e limite da chave”
Q7	Tipo divergente do inteiro, real ou booleano esperado	0/2.800 (0,00%)	“Estatísticas descritivas e domínios numéricos”
Q8	Numéricos não finitos, ausentes ou fora do domínio	0/2.800 (0,00%)	“Estatísticas descritivas e domínios numéricos”
Q9	bpm igual a zero (dado não informado)	1.890/2.800 (67,50%)	“Estatísticas descritivas e domínios numéricos”
Q10	gain igual a zero (a avaliar)	27/2.800 (0,96%)	“Estatísticas descritivas e domínios numéricos”
Q11	Data fora de AAAA-MM-DD, inválida ou fora de 1900 até a coleta	1/2.800 (0,04%)	“Datas, formatos e categorias”
Q12	Espaços nas pontas de título, artista ou gênero	1/2.800 (0,04%)	“Datas, formatos e categorias”

ID	Verificação e regra	Resultado observado	Evidência
Q13	Mais de um nome por id de artista	0/2.800 (0,00%)	“Datas, formatos e categorias”
Q14	Gênero com mais de um nome, ou nome com mais de um id	0/2.800 (0,00%)	“Datas, formatos e categorias”
Q15	Chart geral (id 0), que não é gênero	100/2.800 (3,57%)	“Datas, formatos e categorias”
Q16	Gênero do álbum genérico (id ≤ 0)	11/2.800 (0,39%)	“Datas, formatos e categorias”
Q17	Duração fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	143/2.800 (5,11%)	“Possíveis outliers e integridade do enriquecimento”
Q18	Rank fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q19	Id ausente ou divergente na junção faixa/álbum/artista	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q20	Duração do chart diferente da de /track	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q21	Rank do chart diferente do de /track	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”

Impacto dos problemas identificados

Prioridade: preservar os grupos das P1–P4. Q4 não autoriza descartar as 219 ocorrências excedentes; a preparação mantém o vínculo faixa-chart. Q15 exige separar o chart geral dos gêneros, e Q16 mostra que o gênero do álbum não substitui o de origem. Q11 pede decisão para o lançamento futuro não contar nos 12 meses da P2.

Q9 e Q10 são secundários: P1–P4 e o RA2 não usam BPM nem gain. Q12 pede inspecionar antes de padronizar; Q17, revisar os extremos sem excluí-los, pois IQR não prova erro. Q2 não afeta as perguntas.

Q1, Q5–Q8, Q13–Q14 e Q18–Q21 não acharam ocorrências nos testes executados. As decisões estão na seção 04; esta seção não altera `df_bruto`.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 — Preservação das participações nos charts; Q4, Q5 e Q6.

Problema e abrangência

219/2.800 ocorrências excedentes por id, sem duplicata chart-faixa nem linha igual: a faixa aparece em vários charts. Evidência: notebook §3, "Duplicidade e limite da chave".

Tratamento e justificativa

Uma linha por par chart-faixa: excluir pelo id apagaria participações das P1–P4. Nenhum dos 2.800 registros saiu; a chave final inclui a data da coleta.

Implementação notebook §4, célula "Preservação do vínculo entre faixa e chart".

Validação após o tratamento

Chave composta com 0/2.800 duplicatas e 219/2.800 excedentes por id mantidos. Evidência: notebook §5, "Comparação antes e depois da preparação".

Decisão e diagnóstico D2 — Padronização dos espaços em textos; Q12.

Problema e abrangência

1/2.800: "Sona Mohapatra" com espaço não separável no fim. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Espaços nas pontas removidos de título, artista e chart, preservando acentos e maiúsculas; um campo mudou, nenhum registro saiu.

Implementação notebook §4, célula "Padronização dos campos textuais".

Validação após o tratamento

Texto antes e depois exibido; de 1/2.800 para 0/2.800. Evidência: notebook §5, "Comparação antes e depois da preparação".

Decisão e diagnóstico D3 — Conversão e sinalização das datas de lançamento; Q11.

Problema e abrangência

1/2.800: faixa 4346251442, "Dirty Bird", lançada em 28/10/2026, após a coleta de 16/10/2026; causa não confirmada. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Lançamento convertido para data sem mudar o valor; criados data_coleta (metadados, UTC) e lancamento_posterior_coleta, que separa o futuro dos já ocorridos na P2. Sem exclusão nem estimativa.

Implementação notebook §4, célula "Conversão e validação temporal", e §5, "Padronização dos nomes e tipos".

Validação após o tratamento

2.800 datas convertidas sem perda (formato, calendário e texto conferidos), a futura sinalizada e preservada na releitura. Evidência: notebook §5, "Gravação e releitura do conjunto preparado".

Decisão e diagnóstico D4 — Identificação do chart geral e preservação da origem; Q14, Q15 e Q16.

Problema e abrangência

100/2.800 do chart geral e 11/2.800 com gênero genérico no álbum; ids e nomes de chart consistentes. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Id e nome do chart mantidos e tipo_chart (geral ou genero) criado; o geral serve à P3 e o gênero do álbum não substitui a origem das P1–P4. Sem exclusão nem gênero estimado.

Implementação notebook §4, célula "Identificação do chart de origem".

Validação após o tratamento

100/2.800 com id_chart zero como geral e 2.700/2.800 como genero, origens preservadas. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D5 — Seleção dos atributos do conjunto preparado; Q2, Q3, Q9 e Q10.

Problema e abrangência

Uma prévia e 2.533 versões ausentes, 1.890 BPM e 27 ganhos zerados, em campos fora das P1–P4 e do RA2. Evidências: notebook §3, "Ausências nulas e textos vazios" e "Estatísticas descritivas e domínios numéricos".

Tratamento e justificativa

12 dos 102 atributos mais quatro de contexto ou qualidade: 16 colunas. Os 90 restantes (prévia, versão, BPM, ganho, álbum) ficam no bruto, sem imputação nem exclusão.

Implementação notebook §5, célula "Seleção e organização dos atributos".

Validação após o tratamento

16 colunas do dicionário, sem nulos nos 2.800 registros, com os campos das P1–P4 e os cinco nomes do gerador do RA2. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D6 — Padronização dos nomes e tipos; Q7 e Q8.

Problema e abrangência

Sem problemas de tipo ou domínio nas 2.800, mas nomes da API e datas em texto a organizar. Evidência: notebook §3, "Estatísticas descritivas e domínios numéricos".

Tratamento e justificativa

Nomes em português (rank mantido pelo gerador): oito inteiros, quatro textos, duas datas e dois booleanos. Valores válidos intactos; falha de conversão não vira zero.

Implementação notebook §5, célula "Padronização dos nomes e tipos".

Validação após o tratamento

Inteiros conferidos (ausência, finitude, fração) antes da conversão; domínios, valores e tipos mantidos na releitura. Evidências: notebook §5, "Verificações finais do conjunto preparado" e "Gravação e releitura do conjunto preparado".

Decisão e diagnóstico D7 — Preservação e sinalização dos extremos de duração; Q17 e Q18.

Problema e abrangência

143/2.800 durações fora do IQR (66,5 a 366,5 s) e 0/2.800 ranks. Evidência: notebook §3, "Possíveis outliers e integridade do enriquecimento".

Tratamento e justificativa

Valores mantidos e duracao_fora_limites_iqr criado: extremo não comprova erro, e cortá-lo alteraria a distribuição da P1.

Implementação notebook §4, célula "Sinalização dos extremos de duração".

Validação após o tratamento

143/2.800 sinalizadas pela regra de Q17 e Q18 (seção 03), valores iguais à origem. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D8 — Manutenção e revalidação dos dados aprovados; Q1, Q13 e Q19–Q21.

Problema e abrangência

0/2.800 problemas em campos essenciais, nomes por artista e junções (inclusive duração e rank). Evidências: notebook §3, "Ausências nulas e textos vazios", "Datas, formatos e categorias" e "Possíveis outliers e integridade do enriquecimento".

Tratamento e justificativa

Valores aprovados mantidos e testes repetidos, sem imputação; o df_bruto ficou intacto (a preparação usou uma cópia).

Implementação notebook §5, célula "Verificações finais do conjunto preparado".

Validação após o tratamento

2.800 registros aprovados em obrigatórios, chave, domínios, nomes, datas, sinalizações e integridade; valores iguais ao bruto e releitura igual à memória. Evidência: notebook §5, "Gravação e releitura do conjunto preparado".

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Preservar o vínculo chart-faixa	2.800/2.800 mantidos; 219/2.800 excedentes por id preservados	Notebook §4, "Preservação do vínculo entre faixa e chart"
D2	Remover espaços nas pontas	De 1/2.800 para 0/2.800	Notebook §4, "Padronização dos campos textuais"
D3	Converter e sinalizar datas	2.800 convertidas; 1/2.800 futura mantida e sinalizada	Notebook §4, "Conversão e validação temporal"
D4	Identificar o tipo de chart	100/2.800 do geral identificadas e preservadas	Notebook §4, "Identificação do chart de origem"
D5	Selecionar atributos	12 de origem, 90 não selecionados e quatro novos; 16 finais	Notebook §5, "Seleção e organização dos atributos"
D6	Padronizar nomes e tipos	16 colunas: oito inteiros, quatro textos, duas datas, dois booleanos	Notebook §5, "Padronização dos nomes e tipos"
D7	Sinalizar extremos	143/2.800 sinalizadas, sem exclusão ou alteração	Notebook §4, "Sinalização dos extremos de duração"
D8	Revalidar consistência	2.800/2.800 aprovados pelas regras finais	Notebook §5, "Verificações finais do conjunto preparado"

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final dados/preparados/faixas_preparadas.csv, CSV UTF-8, separador vírgula, sem coluna de índice: 2.800 registros, 16 atributos e 367.932 bytes. Evidência: notebook §5, célula "Gravação e releitura do conjunto preparado", e o próprio CSV.

Unidade de observação final uma ocorrência de faixa em um chart de origem na data da coleta, com chave data_coleta, id_chart e id_faixa; a mesma faixa em charts diferentes não é duplicata. Evidência: notebook §5, célula "Verificações finais do conjunto preparado".

Dicionário atualizado dados/preparados/dicionario-faixas.md, com origem, significado, tipo e domínio dos 16 atributos: oito inteiros, quatro textos, duas datas e dois booleanos. rank manteve o nome por compatibilidade com o gerador de eventos; os demais foram padronizados em português. Evidência: notebook §5, célula "Padronização dos nomes e tipos".

Comparação antes e depois

Evidência: notebook §5, célula "Comparação antes e depois da preparação", sobre o retrato de 16/10/2026. As medidas usam 2.800 registros como denominador e podem se sobrepor; não devem ser somadas.

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	2.800	2.800	Ocorrências preservadas, sem exclusão (D1)
Atributos	102	16	12 atributos de origem e quatro campos de contexto ou qualidade (D5)
Ocorrências com espaços nas pontas	1/2.800 (0,04%)	0/2.800 (0,00%)	Correção textual sem alterar a escrita (D2)
Duplicatas pela chave chart-faixa	0/2.800 (0,00%)	0/2.800 (0,00%)	Unicidade mantida em cada chart e retrato (D1)
Ocorrências excedentes por id da faixa	219/2.800 (7,82%)	219/2.800 (7,82%)	Participações em charts distintos mantidas (D1)
Ocorrências do chart geral	100/2.800 (3,57%)	100/2.800 (3,57%), identificadas	Preservadas e distinguidas pelo tipo de chart (D4)
Lançamentos posteriores à coleta	1/2.800 (0,04%)	1/2.800 (0,04%), sinalizado	Valor da fonte preservado, sem imputar data (D3)

Medida	Após ingestão	Após preparação	Explicação da diferença
Durações fora dos limites IQR	143/2.800 (5,11%)	143/2.800 (5,11%), sinalizadas	Valores preservados, com sinalização de qualidade (D7)

Verificações finais

Os 2.800 registros passaram nas verificações abaixo (notebook §5, células "Padronização dos nomes e tipos" e "Verificações finais do conjunto preparado"):

- As 16 colunas seguem o dicionário, sem nulos nos campos selecionados.
- A chave data-chart-faixa tem 0/2.800 duplicatas e preserva os vínculos de origem.
- Ids de faixa, artista e álbum, posição e duração são inteiros positivos; id_chart, rank e número de fãs, inteiros não negativos.
- Textos sem vazios nem espaços nas pontas; um nome de chart e um nome de artista por id.
- Datas convertidas sem perda; a data da coleta vem dos metadados, e as sinalizações seguem as regras temporal e IQR.
- Identificadores, duração, rank e fãs mantêm os valores de origem, e as junções com faixa, álbum e artista seguem consistentes.
- O df_bruto, comparado com a cópia anterior à preparação, permaneceu intacto.

O CSV foi relido com tipos informados e datas convertidas, e o relido é igual ao conjunto em memória em 2.800 linhas e 16 colunas (notebook §5, célula "Gravação e releitura do conjunto preparado"). Como CSV não guarda tipos, futuras leituras devem reaplicá-los conforme o dicionário.

Limitações e pendências

O conjunto é o retrato de 16/10/2026, com país aparente US: não é série histórica nem permite comparar países. Evidência: dados/brutos/2026-10-16/metadados.json.

A causa da data futura (1/2.800) não foi confirmada; ela foi preservada e sinalizada, e na P2 não deve contar como lançamento já ocorrido nos 12 meses anteriores à coleta. As 143/2.800 durações fora dos limites IQR também foram mantidas e sinalizadas, pois o critério estatístico não comprova erro. Evidências: notebook §4, células "Conversão e validação temporal" e "Sinalização dos extremos de duração".

BPM, ganho, prévia, versão complementar e outros metadados ficaram fora do CSV, mas seguem no retrato bruto; a seleção não os corrige nem estima. Evidência: notebook §5, célula "Seleção e organização dos atributos".

As 100/2.800 ocorrências do chart geral seguem disponíveis para a P3. Os eventos por gênero do RA2 usam só tipo_chart == "genero", 2.700/2.800 ocorrências; o filtro é aplicado na seção 9. Evidência: notebook §4, célula "Identificação do chart de origem".

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/Jcliz/data-analytics • tag entrega, no commit da execução final (o PDF entregue fica em output/entrega-ra1-ra2.pdf nessa tag)

Ambiente Google Colab (referência) ou Python 3.9 ou mais novo em máquina local • versões mínimas em requirements.txt: pandas 2.2 a 2.x e requests 2.31 ou mais novo (RA1), pyspark 4.0.3 com Java 17 ou mais novo (RA2), jupyter, nbconvert, python-docx e pypdf (notebook e PDFs) • conferidas em 16/10/2026 numa instalação limpa: Python 3.13.16, pandas 2.3.3, requests 2.34.2, pyspark 4.0.3, nbconvert 7.17.2, python-docx 1.2.0 e pypdf 6.21.0

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	dados/brutos/2026-10-16/, versionado: respostas cruas da API em JSON (infos.json, generos.json, charts.json, faixas.json, albuns.json, artistas.json, 57,7 MB) e metadados.json (horário, país aparente US, 6.591 chamadas, 0 erros). Nova coleta só com BAIXAR_DA_API = True na seção 00b
Código de ingestão e preparação	notebook/projeto_data_analytics.ipynb, gerado por python scripts/montar_notebook.py a partir de notebook/secoes/ (ambiente em 00b, ingestão em 02, exploração em 03, limpeza em 04, transformação em 05)
Dados preparados	dados/preparados/faixas_preparadas.csv (UTF-8, separador vírgula), regravado pelas seções 04 e 05 a cada execução; nunca editado à mão
Documentação e dependências	README.md (seção "Como executar"), este documento em documentacao/ra1/ (gerado por python scripts/gerar_docx_ra1.py), dados/README.md, requirements.txt e docs/adr/ (decisões)

Passos para reprodução

A reprodução não depende da API (fora do ar, bloqueada ou com outro chart conforme o país e o dia): o notebook lê por padrão o retrato versionado de 16/10/2026, base dos números deste documento. Uma coleta nova (BAIXAR_DA_API = True) grava outra pasta em dados/brutos/, lida por ser a mais recente, e muda todas as contagens; para voltar ao retrato da entrega, apague a pasta nova ou use um clone limpo.

Ordem	Instrução executável	Resultado esperado
1	Preparar o ambiente. No Colab: *Arquivo → Abrir notebook → GitHub*, repositório Jcliz/data-analytics, arquivo notebook/projeto_data_analytics.ipynb. Localmente: git clone https://github.com/Jcliz/data-analytics.git, cd data-analytics, python -m venv .venv, ativar e pip install -r requirements.txt	No Colab, o notebook abre com o RA1 e o RA2. Localmente, pip e python -c "import pandas, requests" terminam sem erro
2	Obter os dados, sem acessar a API: a seção 00b clona o repositório no Colab com BAIXAR_DA_API = False, e a seção 02 lê o retrato versionado em dados/brutos/	"Preparação do ambiente" mostra a raiz do projeto; "Leitura do retrato bruto mais recente", dados/brutos/2026-10-16 e os sete JSON
3	Executar do início ao fim. No Colab: *Ambiente de execução → Executar tudo*. Localmente: python scripts/montar_notebook.py e jupyter nbconvert --to notebook --execute --inplace notebook/projeto_data_analytics.ipynb	Nenhuma célula com erro; na seção 2, df_bruto: 2800 linhas × 102 colunas, 2.581 faixas, 2.292 álbuns, 1.688 artistas e nenhum item sem detalhe ("Verificação do carregamento")
4	Validar a saída: conferir o conjunto preparado e rodar python scripts/verificar_entrega.py	dados/preparados/ faixas_preparadas.csv regravado (seção 05); script sem pendência de notebook desatualizado ou não executado

Verificação da reprodução

Em 20/10/2026, João Correa, que não escreveu o código das seções, seguiu os quatro passos acima a partir de um clone limpo: ambiente novo com pip install -r requirements.txt e execução com jupyter nbconvert --execute, em Linux (WSL2), Python 3.13.5, pandas 2.3.3, requests 2.34.2, PySpark 4.0.3 e Java 21. Resultado: 47 células de código em sequência, sem erro, em 14 s; df_bruto com 2.800 linhas × 102 colunas; dados/preparados/faixas_preparadas.csv regravado idêntico ao versionado; três lotes de 30 eventos processados (90 reproduções); python scripts/verificar_entrega.py sem pendência no notebook.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

DEEZER. *Deezer API*: documentação e API pública (/infos, /genre, /chart/{id}/tracks, /track/{id}, /album/{id}, /artist/{id}). 2026. Disponível em: https://developers.deezer.com/api e https://api.deezer.com. Acesso em: 16/10/2026.

ALVES, Rodrigo et al. *DataAudio*: app Flutter que consome a API da Deezer. 2026. Disponível em: https://github.com/rdsalvesPUC/dataaudio. Acesso em: 16/10/2026.

PYTHON SOFTWARE FOUNDATION. *Python 3.13 documentation*. Versão 3.13. Disponível em: https://docs.python.org/3.13/. Acesso em: 16/10/2026.

PANDAS DEVELOPMENT TEAM. *pandas documentation*. Versão 2.3. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 16/10/2026.

REITZ, Kenneth. *Requests: HTTP for Humans*. Versão 2.34. Disponível em: https://requests.readthedocs.io/. Acesso em: 16/10/2026.

PUCPR. Data Analytics. *PjBL – RA1* (enunciado) e *Template_RA1_Data_Analytics.docx*. 2026. Disponível em: Canvas PUCPR (acesso restrito). Acesso em: 15/10/2026.

PUCPR. Data Analytics. Material de aula: *Data Ingestion and Data Quality*, *From Data Preparation to Data Transformation* e *Data Transformation*. 2026. Disponível em: Canvas PUCPR (acesso restrito). Acesso em: 15/10/2026.

Anexos opcionais

Identificação	Conteúdo	Localização
Anexo A	Dicionário do conjunto preparado	dados/preparados/ dicionario-faixas.md
Anexo B	Metadados da coleta de 16/10/2026	dados/brutos/2026-10-16/ metadados.json

Conferência da entrega

☒ Problema, recorte e perguntas analíticas estão definidos.

☒ Fontes e procedimentos de ingestão estão documentados.

☒ A qualidade foi avaliada com evidências verificáveis.

☒ As decisões de limpeza estão justificadas e validadas.

☒ O conjunto de dados preparado está identificado.

☒ O repositório contém instruções suficientes para reprodução.

☒ Os campos-modelo foram preenchidos e os exemplos revisados.